

개발·의사결정 보고서

정량 분석을 중심으로 한 현재까지의 모델링 결과

작성 기준일 2026-07-14

핵심 결론

데이터

2,574 devices · train/validation/test = 1,802/386/386 · device-level stratified split

전류 처리

IdVd: Vd=0 경계만 0으로 고정 · IdVg: 1e-10 mA/μm 아래를 noise floor로 clip

최종 transform

IdVd = asinh(P10 scale × 1.0), IdVg = floor_log1p(gm/Id knee × 1.0)

최종 scaler

per-coordinate standardization · global 대비 통합 tail score 15.9% 개선

모델 비교

PCA는 IdVd, Residual은 IdVg에 상대적으로 강함. Shared encoder는 task 간 영향 확인

검증 원칙

전처리·모델 선택은 validation만 사용. 최종 test는 고정된 실험에서 1회 사용 예정

1. 문제 정의와 데이터 기반

소자 파라미터에서 전체 I-V curve를 직접 예측

목표는 $L=50\text{ nm}\sim 2\text{ }\mu\text{m}$ 범위를 포함한 구조·도핑 조건으로부터 한 소자의 I_dV_d 와 I_dV_g 전체 곡선을 예측하는 것이다. 두 curve는 같은 소자에서 나오지만 sweep grid와 동적 범위가 달라 독립 head 또는 shared encoder가 필요하다.

입력

L , T , $\log_{10}(B)$, $\log_{10}(SD)$,
 $\log_{10}(LDD)$, fixed bias

출력

I_dV_d : 101 points $\times$ 2 V_g
 I_dV_g : 135 points $\times$ 2 V_d

소자 수

2,574 devices
총 curve samples: 각 5,148

Split

Train 1,802 / Validation 386 / Test 386
70.01% / 14.996% / 14.996%

왜 device-level 계층 split인가?

같은 소자의 I_dV_d/I_dV_g 또는 서로 다른 fixed-bias curve가 train과 validation에 나뉘면 소자 구조를 사실상 미리 본 leakage가 발생한다. 따라서 소자 단위로 먼저 분리하고 L , T , 도핑 단계와 주요 조합의 분포가 세 split에서 유지되도록 greedy stratification을 적용했다.

데이터 결정

원본 전류는 보존하고 학습용 clean array를 별도로 저장한다. 도핑은 파일을 새로 복제하지 않고 입력 시 $\log_{10}$ feature로 사용한다. test 386개 소자는 최종 모델 고정 전까지 선택 지표에서 제외한다.

2. 전류 noise 처리와 평가 기준

평균 오차와 tail/worst-case를 동시에 관리

항목	정의/처리	선정 이유
IdVd 물리 경계	Vd=0인 유일한 점을 정확히 0으로 고정	경계조건 보존, log(0)는 평가 floor로 회피
IdVg noise floor	$I < 1e-10 \text{ mA}/\mu\text{m} \rightarrow 1e-10$	TCAD noise가 학습 loss를 지배하지 않게 함
Linear MAE/RMSE	실제 mA/ μm 오차	on-current 및 절대 전류 정확도
Decade MAE	$\log_{10}(\max(I, \text{floor}))$ 공간 오차	subthreshold 및 작은 전류 구간
NRMSE	curve amplitude로 정규화한 RMSE	크기가 다른 소자 간 비교
P95/P99	curve별 오차 분포의 상위 분위수	평균이 숨기는 worst-case 감시
전기 파라미터	Vth, SS, gm, Ion/Ioff 등 통합 score	curve가 소자 특성을 보존하는지 확인

선택 score

$\text{IdVg} = \text{P95 decade MAE} + 0.1 \times \text{P95 NRMSE}$
 $\text{IdVd} = \text{P95 NRMSE} + 0.25 \times \text{P95 decade MAE}$
공통 설정 = IdVd/IdVg score 평균; 세 모델 finalist = 모델별 score 평균


검증 규칙

초기 baseline/domain 분석에는 이미 생성된 test 보고서가 존재한다. 그러나 이번 물리 transform-scale-scaler 선택의 모든 ranking에는 test_metrics_used=false를 강제했고 validation report만 사용했다. 두 결과군은 보고서에서도 분리한다.


3. 초기 PCA+XGBoost와 도메인 제한 실험

정확도 향상과 coverage 감소를 함께 보고

자체 도메인 coverage



각 모델의 자체 지원 도메인




도메인	Coverage	IdVd RMSE	IdVg RMSE	해석
Full	100.0%	0.0998	0.0695	범용 모델; 악독한 corner 포함
v1	97.9%	0.0909	0.0645	두꺼운 산화막+고도핑 동시 corner 제외
v2	83.7%	0.0638	0.0547	validation worst-case 기반 공격적 제한

결정: 제한 모델은 정확도를 높이지만 예측 가능 영역을 줄인다. 따라서 full model을 기본 비교축으로 유지하고, 제한 모델은 입력 domain warning과 함께 별도 모델로 관리한다.


4. 동일 도메인에서 본 초기 모델 품질

v2가 지원하는 동일 323개 test device에서 비교한 과거 baseline 결과

동일 323-device curve 오차



추출 전기 파라미터 통합 오차



정량 해석: v2는 동일 도메인에서 Full 대비 IdVd 평균 MAE를 3.5%, IdVg 평균 MAE를 10.8% 줄였고, 전기 파라미터 통합 score를 0.433→0.203으로 53.2% 낮췄다. 반면 일부 absolute maximum curve error는 Full/v1이 더 작아 v2가 모든 worst case를 해결한 것은 아니다.

모델 방향 전환

단순히 어려운 소자를 제외하는 것만으로는 범용 모델 목표를 달성할 수 없다. 이후에는 full-domain을 유지하면서 transform과 architecture를 개선하는 방향으로 전환했다. PCA+XGBoost, Residual MLP, Shared encoder+separate heads의 세 축을 비교한다.

5. 물리·수학 기반 target transform 설계

원본 curve를 축소하지 않고 invertible transform만 적용

차원 축소된 target만 직접 학습하면 작은 전류, knee, 국소 기울기 같은 물리 정보를 잃을 위험이 있다. 따라서 최종 공통 전처리는 curve point 수를 그대로 유지하고, 동적 범위만 완화하는 단조·역변환 가능 transform을 사용한다.

대상	Forward	Inverse/fit	이유
IdVd	$z = \operatorname{asinh}(I / s)$	$I = s \cdot \sinh(z)$	0 근처 선형 + 큰 전류 로그형; 부호·Vd=0 보존
IdVg	$z = \log_{10}(\max(I - I_{\text{floor}}, 0) / s)$	$I = I_{\text{floor}} + s \cdot \exp_{10}(z)$	noise floor 아래 제거 + subthreshold decade 압축
Scale	IdVd: positive-current P10	bias별 train curve에서 fit	고정 상수보다 데이터의 실제 전류 크기 반영
Scale	IdVg: gm/Id knee current	train curve의 median knee	weak→strong inversion 전환에 물리적 기준 부여

비교한 scaler


per-coordinate: 각 sweep voltage point별 train mean/std 사용
global: curve 전체에 하나의 train mean/std 사용

안전장치

transform, current scale, scaler는 train curve에서만 fit한다. validation은 후보 선택에만 사용하고 test target은 읽어 성능을 계산하지 않는다. 모든 fitted parameter는 target_transform.json에 저장해 inference에서 정확히 역변환한다.

6. IdVg gm/Id knee scale 선별

Residual screening baseline · validation only · 772 curves




순위	knee 배율	Linear RMSE	P95 NRMSE	P95 decade	Score
1	×1p0	0.3773	0.0650	1.1767	1.1832
2	×0p3	0.2799	0.0557	1.3248	1.3304
3	×3p0	0.3033	0.0662	1.7140	1.7206

결정 · 1.0× knee

0.3×가 선형 RMSE와 P95 NRMSE는 더 작았지만 P95 decade MAE가 1.3248로 증가했다. 1.0×는 P95 decade 1.1767로 가장 낮아 종합 score가 2위보다 11.1% 우수했다. 계산된 knee current는 0.0158846 mA/μm이다.

7. IdVd asinh scale 선별

IdVg winner를 고정하고 P10 current 배율만 비교



순위	P10 배율	Linear RMSE	P95 NRMSE	P95 decade	Score
1	×1p0	0.5858	0.0744	0.0441	0.0854
2	×3p0	0.5441	0.0825	0.0500	0.0950
3	×0p3	0.5281	0.0871	0.0537	0.1005


결정 · 1.0×와 3.0×를 finalist로 승격

1.0×가 tail score 0.0854로 1위였고 3.0×보다 10.1% 낮았다. 3.0×는 선형 RMSE가 더 작아 architecture에 따라 이점이 있을 가능성이 있으므로 두 후보 모두 세 모델 full baseline 비교로 넘겼다.


8. 세 모델 공통 transform finalist 비교

후보 2개 × 모델 3개 · 동일 validation · test 미사용

모델별 후보 민감도



공통 transform 순위



IdVd scale	모델	IdVd RMSE	IdVg RMSE	Tail score	전기추출 성공
1.0×	PCA+XGB	0.1080	0.2622	0.7191	206
1.0×	Residual	0.4205	0.1875	0.6811	249
1.0×	Shared	0.4464	0.2738	0.7345	105
3.0×	PCA+XGB	0.1160	0.2622	0.7215	206
3.0×	Residual	0.2267	0.1875	0.6689	249
3.0×	Shared	0.3162	0.2070	0.9611	131

결정: 3.0×는 Residual과 Shared의 선형 RMSE를 개선했지만 Shared IdVg P95 decade가 1.396→1.853으로 악화됐다. 공통 encoder를 통해 IdVd 조건이 IdVg에 영향을 준 결과다. 3-model 평균 score가 9.2% 낮은 1.0×를 공통 winner로 선택했다.

9. Architecture별 정량 해석

아직 최종 model winner가 아니라 전처리 고정을 위한 baseline 비교

모델	최저 RMSE 후보	IdVd RMSE	IdVg RMSE	관찰	해석
PCA+XGBoost	1.0×	0.1080	0.2622	IdVd에 가장 강함	curve 저차 구조를 PCA가 효율적으로 표현
Residual MLP	3.0×	0.2267	0.1875	IdVg에 가장 강함직접	multi-output으로 비선형 curve 형상 학습
Shared encoder	3.0×	0.3162	0.2070	공유 효과 확인	IdVd 변화가 IdVg에도 전달; task balance 필요

전기 파라미터 추출 성공률

Scale	모델	성공	실패	성공률
1.0×	PCA+XGB	206	180	53.4%
1.0×	Residual	249	137	64.5%
1.0×	Shared	105	281	27.2%
3.0×	PCA+XGB	206	180	53.4%
3.0×	Residual	249	137	64.5%
3.0×	Shared	131	255	33.9%

주의: Shared의 낮은 추출 성공률은 curve RMSE만으로 물리적 형상 보존을 보장할 수 없음을 보여준다. 향후 loss에는 slope/shape 및 IdVd-IdVg consistency를 모델별 개선 항목으로 검토해야 한다.

공통 transform을 고정하고 scaler만 변경



최종 결정 · per-coordinate

Inverse Device Modeling · Curve Model

11. 고정된 공통 전처리와 다음 단계

Step 1~7 완료 · 이후에는 preprocessing을 변경하지 않고 모델별 최적화

단계	최종 설정	비고
IdVd clean	Vd=0 boundary → 0	물리 경계조건
IdVd transform	asinh, positive-current P10 ×1.0	bias별 train scale: 0.1824 / 0.5658 mA/μm
IdVg clean	I < 1e-10 → 1e-10 mA/μm	noise 제거
IdVg transform	floor_log1p, gm/Id knee ×1.0	train knee: 0.0158846 mA/μm
Scaler	per-coordinate	각 sweep point를 train mean/std로 표준화
Selection	validation P95 tail 중심	test_metrics_used=false

다음 실험 우선순위

- 1) PCA+XGBoost: component/estimator search를 최종 transform에서 재수행하고 tail score를 목적함수로 사용
- 2) Residual MLP: width-block-learning rate-loss weight 최적화, multi-seed 안정성 확인
- 3) Shared encoder: task-loss balance, head capacity, shared/private representation 및 consistency loss 검토
- 4) 세 모델을 고정한 뒤 동일 validation report로 최종 모델 선택
- 5) 모든 선택 완료 후 test를 단 1회 평가하고 GUI/inference artifact를 export

현재 결론의 범위

최종 preprocessing은 고정됐지만 최종 model winner는 아직 아니다. 현재 비교는 baseline architecture에서 전처리의 일관성을 검증한 결과다. 특히 Shared encoder의 전기 파라미터 추출 실패와 IdVg decade tail은 개선 대상이다.

부록. 재현 경로와 결정 추적

보고서 수치는 아래 JSON artifact에서 직접 읽어 생성

핵심 artifact

- 1. ai/model_artifacts/curve_model/dataset/metadata.json
- 2. ai/model_artifacts/curve_model/pca_xgboost_worst_v2/evaluation/three_domain_comparison.json
- 3. ai/model_artifacts/curve_model/preprocessing_screen/idvg_knee/idvg_ranking.json
- 4. ai/model_artifacts/curve_model/preprocessing_screen/idvd_scale/idvd_ranking.json
- 5. ai/model_artifacts/curve_model/preprocessing_finalists/finalist_ranking.json
- 6. ai/model_artifacts/curve_model/preprocessing_screen/scaler/both_ranking.json
- 7. ai/curve_model/configs/preprocessing/selected_physical.json

재현 명령

```
python ai/curve_model/tools/optimization/screen_target_transforms.py --stage scaler --base-config ai/model_artifacts/curve_model/preprocessing_screen/transform_winner.json --run
python ai/curve_model/tools/optimization/compare_preprocessing_results.py --stage-dir ai/model_artifacts/curve_model/preprocessing_screen/scaler --kind both
python ai/curve_model/reports/generate_progress_report.py
```

본 PDF는 저장된 artifact를 수정하지 않고 읽어서 생성한다. 모델 선택 관련 ranking은 selection_split=validation, test_metrics_used=false를 명시한다. 수치 반올림 때문에 표의 마지막 자릿수는 원본 JSON과 미세하게 다를 수 있다.